

Analisis Exploratorio de Datos

Deteccion de Fraude en Seguros de Auto

Modulo 2 Temas 4 y 5

Equipo 3

Nombre	Titulacion
APELLIDO Nombre1	SI / NO
APELLIDO Nombre2	SI / NO
APELLIDO Nombre3	SI / NO
Ruiz Carbajal Ismael	SI


1. Clasificacion y Explicacion de las Columnas

El dataset contiene 1,000 registros y 40 variables (39 tras eliminar _c39). Las columnas se agrupan en seis bloques: perfil del asegurado, detalles de la póliza, detalles del incidente, costos del reclamo, datos del vehículo y la variable objetivo fraud_reported.

2. Analisis Inicial

2.1 Perfil del Asegurado


Perfil del asegurado



La mayoría de las variables presentan una distribución relativamente uniforme. Las variables de capital muestran sesgo positivo con concentración cercana a cero. La distribución por edad muestra mayor concentración en edades medias y avanzadas.

Interpretacion pendiente: 2.1 Perfil del Asegurado — completar interpretacion


2.2 Piramide de Poblacion



Interpretacion pendiente: 2.2 Piramide de Poblacion — completar interpretacion

2.3 Detalles de la Poliza


Detalles de la Póliza



Interpretacion pendiente: 2.3 Detalles de la Poliza — completar interpretacion

2.4 Detalles del Siniestro


Detalles del Siniestro



Interpretacion pendiente: 2.4 Detalles del Siniestro — completar interpretacion

2.5 Costos del Reclamo

Costos de Reclamo



Interpretacion pendiente: 2.5 Costos del Reclamo — completar interpretacion

2.6 Datos del Vehiculo

The figure consists of three bar charts arranged horizontally, each representing a different dimension of car data.


- Distribución de Auto_make:** A bar chart showing the frequency of different car makes. The y-axis is labeled 'Frecuencia' and ranges from 0 to 80. The x-axis lists 15 car makes. The bars are dark blue.
- Distribución de Auto_model:** A bar chart showing the frequency of different car models. The y-axis is labeled 'Frecuencia' and ranges from 0 to 40. The x-axis lists 30 car models. The bars are dark blue.
- Histograma de Auto_year:** A histogram showing the frequency of car years. The y-axis is labeled 'Frecuencia' and ranges from 0 to 50. The x-axis is labeled 'Auto_year' and ranges from 1995.0 to 2015.0. The bars are dark blue.

Interpretacion pendiente: 2.6 Datos del Vehiculo — completar interpretacion

3. Relacion con el Fraude

3.1 Variables financieras por grupo de fraude


Variables vs Fraude



Interpretacion pendiente: 3.1 Variables financieras por grupo de fraude — completar interpretacion


3.2 Distribucion del monto de reclamacion por fraude

Distribución Monto de Reclamación segregando por fraude




Interpretacion pendiente: 3.2 Distribucion del monto de reclamacion por fraude — completar interpretacion

3.3 Tasa de fraude por hora del incidente




Interpretacion pendiente: 3.3 Tasa de fraude por hora del incidente — completar interpretacion

3.4 Heatmap: tasa de fraude por ocupacion



Interpretacion pendiente: 3.4 Heatmap: tasa de fraude por ocupacion — completar interpretacion


3.5 Densidades por ocupacion y hora del siniestro



Interpretacion pendiente: 3.5 Densidades por ocupacion y hora del siniestro — completar interpretacion

3.6 Proporciones de fraude por variable categorica (Plotly)

Nota: exportar la figura de Plotly manualmente como PNG usando el icono de camara y guardarla como figuras_pdf/proporciones_fraude.png antes de generar el PDF.BORRAR ESTE TEXTO CUANDO YA SE VEA LA IMAGEN



Interpretacion pendiente: 3.6 Proporciones por categoria — completar interpretacion


4. Pruebas de Hipotesis

4.1 Chi-cuadrada: variables categoricas vs. fraude

Se aplico la prueba Chi-cuadrada de independendencia sobre variables numericas (total_claim_amount, vehicle_claim, injury_claim, property_claim, age, months_as_customer) contra fraud_reported, usando tablas de contingencia.


Interpretacion pendiente: 4.1 Resultados Chi-cuadrada — completar interpretacion

4.2 Mann-Whitney y Levene: variables numericas por fraude



Interpretacion pendiente: 4.2 Mann-Whitney y Levene — completar interpretacion

4.3 Bootstrap: diferencia en tasa de fraude por sexo



Resultado muy útil ya que si encerramos al 0 en nuestro intervalo de confianza podemos decir que hay evidencia estadística que la diferencia de tasas es 0, es decir ambas tasas son iguales.

5. Conclusiones

Para la prueba de Chi-Cuadrada el p-value es mayor que 0.05, por lo que no podemos rechazar la hipótesis nula: las variables analizadas no muestran asociación estadísticamente significativa con la etiqueta de fraude a ese nivel de confianza. Para las pruebas de Mann-Whitney y Levene se observa diferencia significativa en algunas variables numéricas entre los grupos de fraude y no fraude.

Interpretación pendiente: Conclusiones adicionales — completar por equipo